Czy model „rozumie”, co widzi?

Wyjaśnienia wizualne głębokich modeli a semantyka obiektów i scen

Czy aktywacje generowane przez głębokie modele uczenia maszynowego (Grad-CAM, LRP, saliency maps) odzwierciedlają zrozumienie semantyki obrazu, czy jedynie powierzchowne rozpoznanie wzorców - wiedzę o tym, *gdzie spojrzeć*, żeby coś zaklasyfikować.

Projekt monograficzny - 2026-10-15
Autor: Kacper Borys
Promotor: prof. dr hab. inż. Halina Kwaśnicka
Prezentacja częściowo stworzona przy pomocy AI

1. Cel, zakres i pytania badawcze

Cel Czy wyjaśnienia generowane przez modele głębokie *ujawniają zrozumienie semantyki* obrazów, czy tylko *odzwierciedlają powierzchowne rozpoznawanie wzorców.*

Zakres Analiza i porównanie wyjaśnień wizualnych: Grad-CAM, LRP, saliency maps oraz inne metody (możliwie autorskie) w kontekście semantycznych cech obiektów i scen.

Znaczenie Zaufanie do modeli: interpretowalność ∩ semantyka. Wyjaśnienie ≠ wyjaśnienie *dobrze.*

Definicja „rozumienia semantycznego” Do zrobienia jako część pracy

Pytania badawcze

- **1.** Czy heatmapy pokrywają się z obszarami istotnymi semantycznie dla człowieka?
- **2.** Czy wyjaśnienia różnicują klasy bliskie semantycznie (wilk / pies, samolot / dron, labrador / golden retriever)?
- **3.** ...?

2. Metodologia

Etap 1 · Teoria

- **Interpretowalność** i XAI dla obrazów.
- **Semantyka** vs. rozpoznanie wzorców.
- **Metody:** CAM ⟶ Grad--CAM ⟶ LRP ⟶ saliency / integrated gradients.
- **Definicja** „rozumienia semantycznego” w AI.
- **Krytyka:** zawodność i niestabilność saliency maps.

Etap 2 · Eksperyment

- **Modele:** ResNet50, EfficientNet.
- **Klasy bliskie semantycznie:** labrador / golden retriever, wilk / pies, samolot / dron.
- **Ta sama sieć,** różne metody wyjaśnień.
- **Semantic probing:** probe'y uczące się atrybutów (Visual Genome, CUB-200).

Etap 3 · Ocena

- **IoU** wyjaśnień z maskami segmentacji semantycznej.
- **Pixel-wise overlap** między metodami.
- **Semantyczna trafność** / zgodność semantyczna wyjaśnień.
- **Analiza błędów:** heatmapy „off tangent”, preteksty.
- **Wnioski** + kierunki dalszych badań.

3. Literatura i kierunki dalszych badań

Metody wyjaśnień wizualnych

- Zeiler & Fergus (2014) — Visualizing and Understanding Convolutional Networks, ECCV
- Zhou i in. (2016) — Learning Deep Features for Discriminative Localization (CAM), CVPR
- Selvaraju i in. (2020) — Grad-CAM, IJCV 128(2)
- Binder i in. (2016) — Layer-wise Relevance Propagation for Neural Networks with Local Renormalization Layers, arXiv:1604.00825

Zastosowania XAI

- Szymkowski (2023) — Neural Networks and Saliency Maps in Diabetic Retinopathy Diagnosis, Springer
- Peiffer (2024) — An Experimental Investigation into the Evaluation of Explainability Methods

Krytyka metod i metryki wyjaśnień

- Kindermans i in. (2017) — The (Un)reliability of Saliency Methods, arXiv:1711.00867
- Adebayo i in. (2020) — Sanity Checks for Saliency Maps, NeurIPS
- Rosenzweig i in. (2023) — When Saliency Goes off on a Tangent, arXiv:2110.06639
- Lin i in. (2019) — Do Explanations Reflect Decisions?, arXiv:1910.07387
- Raatikainen & Rahtu (2025) — The Weighting Game: Evaluating Quality of Explainability Methods, LNCS 15726
- Pawlicki i in. (2024) — Evaluating the Necessity of the Multiple Metrics for Assessing Explainable AI, Neurocomputing 602
- Szczepankiewicz i in. (2023) — Ground Truth Based Comparison of Saliency Maps Algorithms, Scientific Reports 13

Semantyka vs. rozpoznanie wzorców

- Yan & Zhou (2017) — How Intelligent Are Convolutional Neural Networks?, arXiv
- Bau i in. (2017) — Network Dissection: Quantifying Interpretability of Deep Visual Representations, CVPR
- Kim i in. (2018) — Interpretability Beyond Feature Attribution: TCAV, ICML
- Chen i in. (2020) — Concept Whitening for Interpretable Image Recognition, Nat. Mach. Intell. 2
- Geirhos i in. (2019) — ImageNet-trained CNNs are Biased towards Texture, ICLR
- Geirhos i in. (2020) — Shortcut Learning in Deep Neural Networks, Nat. Mach. Intell. 2
- Zellers i in. (2019) — From Recognition to Cognition: Visual Commonsense Reasoning, CVPR